¡Hola, Carlos!

Mi nombre es Carlos Ortiz, soy code reviewer de Practicum y voy a revisar el proyecto que acabas de desarrollar.

Cuando vea un error la primera vez, lo señalaré. Deberás encontrarlo y arreglarlo. La intención es que te prepares para un espacio real de trabajo. En un trabajo, el líder de tu equipo hará lo mismo. Si no puedes solucionar el error, te daré más información en la próxima ocasión.

Encontrarás mis comentarios más abajo - **por favor, no los muevas, no los modifiques ni los borres.**

¿Cómo lo voy a hacer? Voy a leer detenidamente cada una de las implementaciones que has llevado a cabo para cumplir con lo solicitado. Verás los comentarios de esta forma:

Comentario del revisor Si todo está perfecto.

Comentario del revisor Si tu código está bien pero se puede mejorar o hay algún detalle que le hace falta.

Comentario del revisor Si de pronto hace falta algo o existe algún problema con tu código o conclusiones.

Puedes responderme de esta forma:

Respuesta del estudiante

¡Empecemos!

Análisis del riesgo de incumplimiento de los prestatarios

Tu proyecto consiste en preparar un informe para la división de préstamos de un banco. Deberás averiguar si el estado civil y el número de hijos de un cliente tienen un impacto en el incumplimiento de pago de un préstamo. El banco ya tiene algunos datos sobre la solvencia crediticia de los clientes.

Tu informe se tendrá en cuenta al crear una **puntuación de crédito** para un cliente potencial. La **puntuación de crédito** se utiliza para evaluar la capacidad de un prestatario potencial para pagar su préstamo.

Abre el archivo de datos y mira la información general.

In [1]:
```
# Cargar todas las librerías
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

In [2]:
```
try:
    df = pd.read_csv('credit_scoring_eng.csv', sep=',')
except:
    df = pd.read_csv('/datasets/credit_scoring_eng.csv', sep=',')
```

Respuesta del estudiante Las celdas fueron separadas para que mostraran ambas partes del codigo por separado.

Ejercicio 1. Exploración de datos

Descripción de los datos

- `children` - el número de hijos en la familia
- `days_employed` - experiencia laboral en días
- `dob_years` - la edad del cliente en años
- `education` - la educación del cliente
- `education_id` - identificador de educación
- `family_status` - estado civil
- `family_status_id` - identificador de estado civil
- `gender` - género del cliente
- `income_type` - tipo de empleo
- `debt` - ¿había alguna deuda en el pago de un préstamo?
- `total_income` - ingreso mensual
- `purpose` - el propósito de obtener un préstamo

In [3]:
```
# Vamos a ver cuántas filas y columnas tiene nuestro conjunto de datos

df.shape
```

Out[3]: (21525, 12)

In [4]:
```
# vamos a mostrar las primeras filas N

df.head(10)
```

Out[4]:

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gende
0	1	-8437.673028	42	bachelor's degree	0	married	0	
1	1	-4024.803754	36	secondary education	1	married	0	
2	0	-5623.422610	33	Secondary Education	1	married	0	N
3	3	-4124.747207	32	secondary education	1	married	0	N
4	0	340266.072047	53	secondary education	1	civil partnership	1	
5	0	-926.185831	27	bachelor's degree	0	civil partnership	1	N
6	0	-2879.202052	43	bachelor's degree	0	married	0	
7	0	-152.779569	50	SECONDARY EDUCATION	1	married	0	N
8	2	-6929.865299	35	BACHELOR'S DEGREE	0	civil partnership	1	
9	0	-2188.756445	41	secondary education	1	married	0	N

Respuesta del estudiante Si, existe un problema, en la data de $days_employed$ la mayoria de los valores son negativos, pude tambien apreciar que education hay informacion en minuscula, en mayuscula, con mayuscula al inicio y luego las demas letras en minuscula, aparte de signos de puntuacion como los apostrofes, todos estos pequeños detalles tendran que ser corregidos para poder utilizar esa data mas adelante.

In [5]:

```
# Obtener información sobre los datos

df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 21525 entries, 0 to 21524
Data columns (total 12 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   children          21525 non-null  int64
 1   days_employed     19351 non-null  float64
 2   dob_years         21525 non-null  int64
 3   education         21525 non-null  object
 4   education_id      21525 non-null  int64
 5   family_status     21525 non-null  object
 6   family_status_id  21525 non-null  int64
 7   gender            21525 non-null  object
 8   income_type       21525 non-null  object
 9   debt              21525 non-null  int64
```

```
 10  total_income      19351 non-null  float64
 11  purpose           21525 non-null  object
dtypes: float64(2), int64(5), object(5)
memory usage: 2.0+ MB
```

Respuesta del estudiante Aca agregue el parentesis como se necesitaba.

Respuesta del estudiante Si, hay valores ausentes, pero solo en algunas columnas.

In [6]:

```
# Veamos la tabla filtrada con valores ausentes de la primera columna donde faltan dato

df_filtrado = df[df.isnull().any(axis=1)]
df_filtrado
```

Out[6]:

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	g
12	0	NaN	65	secondary education	1	civil partnership	1	
26	0	NaN	41	secondary education	1	married	0	
29	0	NaN	63	secondary education	1	unmarried	4	
41	0	NaN	50	secondary education	1	married	0	
55	0	NaN	54	secondary education	1	civil partnership	1	
...	...	...	...	...	...	...	...	
21489	2	NaN	47	Secondary Education	1	married	0	
21495	1	NaN	50	secondary education	1	civil partnership	1	
21497	0	NaN	48	BACHELOR'S DEGREE	0	married	0	
21502	1	NaN	42	secondary education	1	married	0	
21510	2	NaN	28	secondary education	1	married	0	

2174 rows × 12 columns

Respuesta del estudiante 1) Los valores son asimetricos 2) Si, ya que tenemos mas filas que columnas. 3) Seria bueno hacer la investigacion de los valores ausentes, pero entiendo que eso

no variaria las observaciones de simetria del dataframe ofrecido.

In [7]:

```
# Aplicar múltiples condiciones para filtrar datos y contar filas en la tabla filtrada

condiciones = (df['children'] >= 3) & (df['total_income'] >= 100) & (df['dob_years'] <=
df_filtrado = df[condiciones]

# Contar filas en la tabla filtrada
num_filas_filtradas = len(df_filtrado)

# Mostrar la tabla filtrada y el número de filas
print("\nTabla filtrada con las siguientes condiciones:")
print(df_filtrado)
"Número de filas en la tabla filtrada:", num_filas_filtradas
```

```
Tabla filtrada con las siguientes condiciones:
       children  days_employed  dob_years            education  education_id  \
3             3   -4124.747207         32  secondary education             1
270           3   -1872.663186          0  secondary education             1
294           4   -2220.384765         36    bachelor's degree             0
352           3   -2949.422637         35  secondary education             1
606          20    -880.221113         21  secondary education             1
...         ...            ...        ...                  ...           ...
21333         4   -2927.000229         38  secondary education             1
21470         3   -1555.901115         38    bachelor's degree             0
21484         3    -968.718123         35  secondary education             1
21491        20    -173.954460         27  secondary education             1
21523         3   -3112.481705         38  secondary education             1

           family_status  family_status_id gender income_type  debt  \
3                married                 0      M    employee     0
270              married                 0      F    employee     0
294    civil partnership                 1      F    employee     0
352              married                 0      M    business     0
606              married                 0      M    business     0
...                  ...               ...    ...         ...   ...
21333            married                 0      M    employee     0
21470            married                 0      M    business     0
21484            married                 0      M    employee     0
21491            married                 0      F    employee     0
21523            married                 0      M    employee     1

       total_income                   purpose
3         42820.568   supplementary education
270       16346.633        housing renovation
294       53603.948          wedding ceremony
352       30804.632                       car
606       23253.578     purchase of the house
...             ...                       ...
21333     21125.122       building a property
21470     33680.795        to become educated
21484     15306.792                   housing
21491     24883.344  buying a second-hand car
21523     39054.888         buying my own car

[290 rows x 12 columns]
```

Out[7]:

```
('Número de filas en la tabla filtrada:', 290)
```

Respuesta del estudiante Agregare un paso extra antes de proceder, para saber el porcentaje

de valores ausentes y asi tener mejor idea de que decision tomar mas adelante.

In [8]:

```
# Aca calcule el porcentaje de los valores ausentes en comparacion con el conjunto de d

num_total_celdas = df.size
num_valores_ausentes = df.isnull().sum().sum()

porcentaje_valores_ausentes = (num_valores_ausentes / num_total_celdas) * 100

f"Porcentaje de valores ausentes en el conjunto de datos: {porcentaje_valores_ausentes:
```

Out[8]:

```
'Porcentaje de valores ausentes en el conjunto de datos: 1.68%'
```

Respuesta del estudiante 1) El numero de filas no coincide con el numero de valores ausentes. 2) Como el numero de valores ausentes no es tan significativo, teniendo en cuenta que tenemos una tabla asimetrica donde el numero de columnas no se corresponde con el numero de filas y viendo que la porcion de datos ausentes esta mas marcada en columnas especificas, hay que tomar accion sobre ellos (los valores ausentes)

In [9]:

```
# Vamos a investigar a los clientes que no tienen datos sobre la característica identif

# Contar la cantidad de valores nulos en cada columna del DataFrame
nulos_por_columna = df.isnull().sum()

# Mostrar el número total de valores nulos en cada columna con su respectivo nombre de
print("Número total de valores nulos en cada columna:")
for columna, cantidad_nulos in nulos_por_columna.iteritems():
    print(f"{columna}: {cantidad_nulos}")
```

```
Número total de valores nulos en cada columna:
children: 0
days_employed: 2174
dob_years: 0
education: 0
education_id: 0
family_status: 0
family_status_id: 0
gender: 0
income_type: 0
debt: 0
total_income: 2174
purpose: 0
```

In [10]:

```
# Comprobación de la distribución

columnas_numericas = df.select_dtypes(include='number').columns

for columna in columnas_numericas:
    asimetria = df[columna].skew()
    if asimetria > 0:
        print(f"La variable '{columna}' es asimétrica positiva.")
    elif asimetria < 0:
        print(f"La variable '{columna}' es asimétrica negativa.")
```

```
    else:
        f"La variable '{columna}' es simétrica."
```

```
La variable 'children' es asimétrica positiva.
La variable 'days_employed' es asimétrica positiva.
La variable 'dob_years' es asimétrica positiva.
La variable 'education_id' es asimétrica positiva.
La variable 'family_status_id' es asimétrica positiva.
La variable 'debt' es asimétrica positiva.
La variable 'total_income' es asimétrica positiva.
```

Respuesta del estudiante 1) Segun se puede observar la distribucion es asimetrica positiva, digase que no es equitativa. 2) Mi parecer sobre la causa de la ausencia de datos es que probablemente los clientes de manera deliberada omitieron esta informacion, ya que como es el 1.68% de la data que esta ausente, dificilmente seria tan significativa como para dañar la muestra. 3) No creo que la data este ausente al azar.

In [11]:

```
# Comprobando la distribución en el conjunto de datos entero

asimetria_total = df.skew().mean()

if asimetria_total > 0:
    print("El conjunto de datos tiene asimetría positiva.")
elif asimetria_total < 0:
    print("El conjunto de datos tiene asimetría negativa.")
else:
    "El conjunto de datos es simétrico."
```

```
El conjunto de datos tiene asimetría positiva.
```

Respuesta del estudiante 1) Si, la distribucion es similar en el conjunto de datos original y en la tabla filtrada. 2) Si la distribución de la tabla filtrada es muy diferente a la del conjunto de datos original, entonces los resultados obtenidos a partir de la tabla filtrada podrían ser engañosos o incorrectos, entonces, como son similares, se pueden utilizar sin problemas.

In [12]:

```
# Comprueba otras razones y patrones que podrían llevar a valores ausentes

plt.figure(figsize=(10, 6))
sns.heatmap(df.isnull(), cmap='viridis', cbar=False)
plt.title('Mapa de calor de valores ausentes')
plt.show()
```

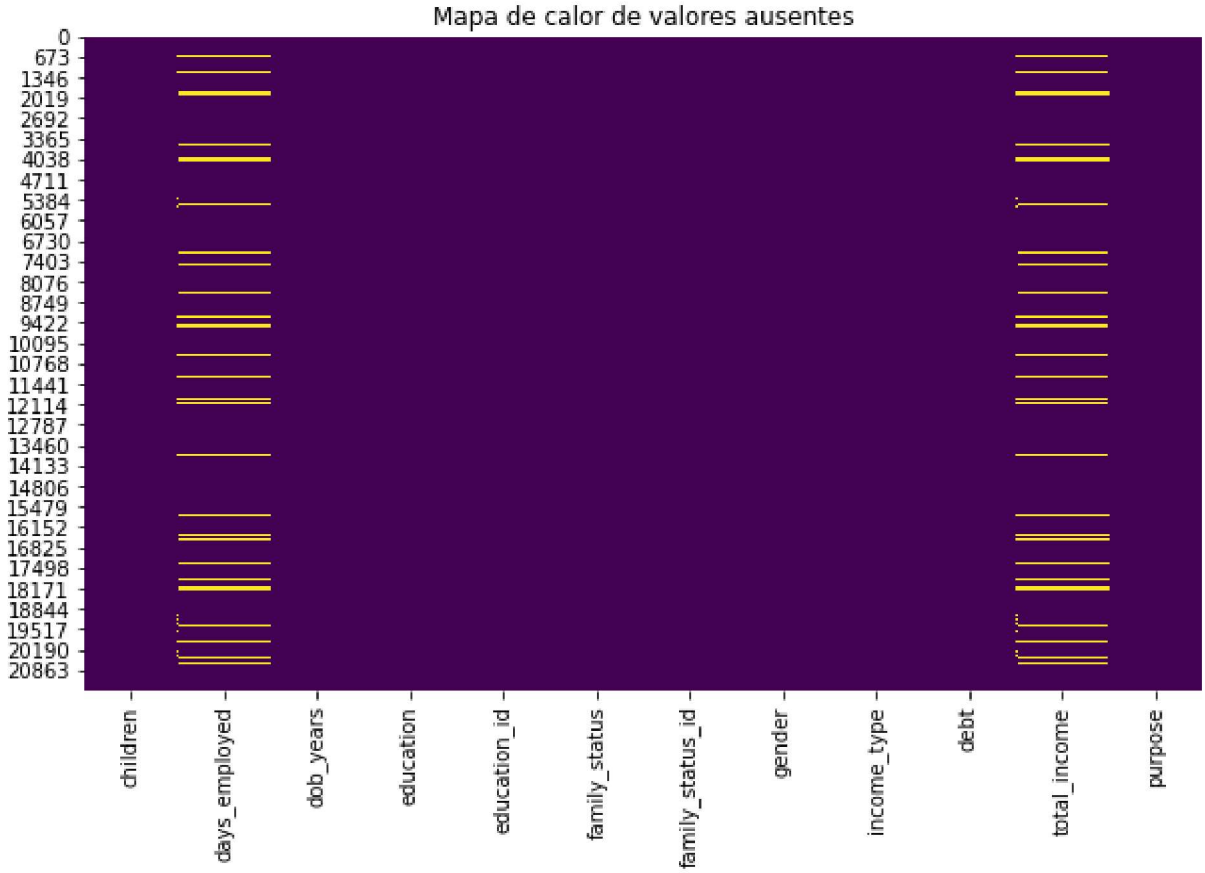

Respuesta del estudiante Al parecer los valores ausentes si son accidentales, pero hare una ultima comprobacion comparando los datos con otro tipo de grafica con diferente enfoque, para tener constancia de la realidad de los hechos.

In [13]:

```
# Comprobación de otros patrones: explica cuáles

valores_ausentes = df.isnull().sum()

# Graficar la cantidad de valores nulos por columna en un gráfico de barras
plt.figure(figsize=(10, 6))
valores_ausentes.plot(kind='bar', color='skyblue')
plt.title('Cantidad de Valores Ausentes por Columna')
plt.xlabel('Columnas')
plt.ylabel('Cantidad de Valores Ausentes')
plt.xticks(rotation=45, ha='right')
plt.show()
```

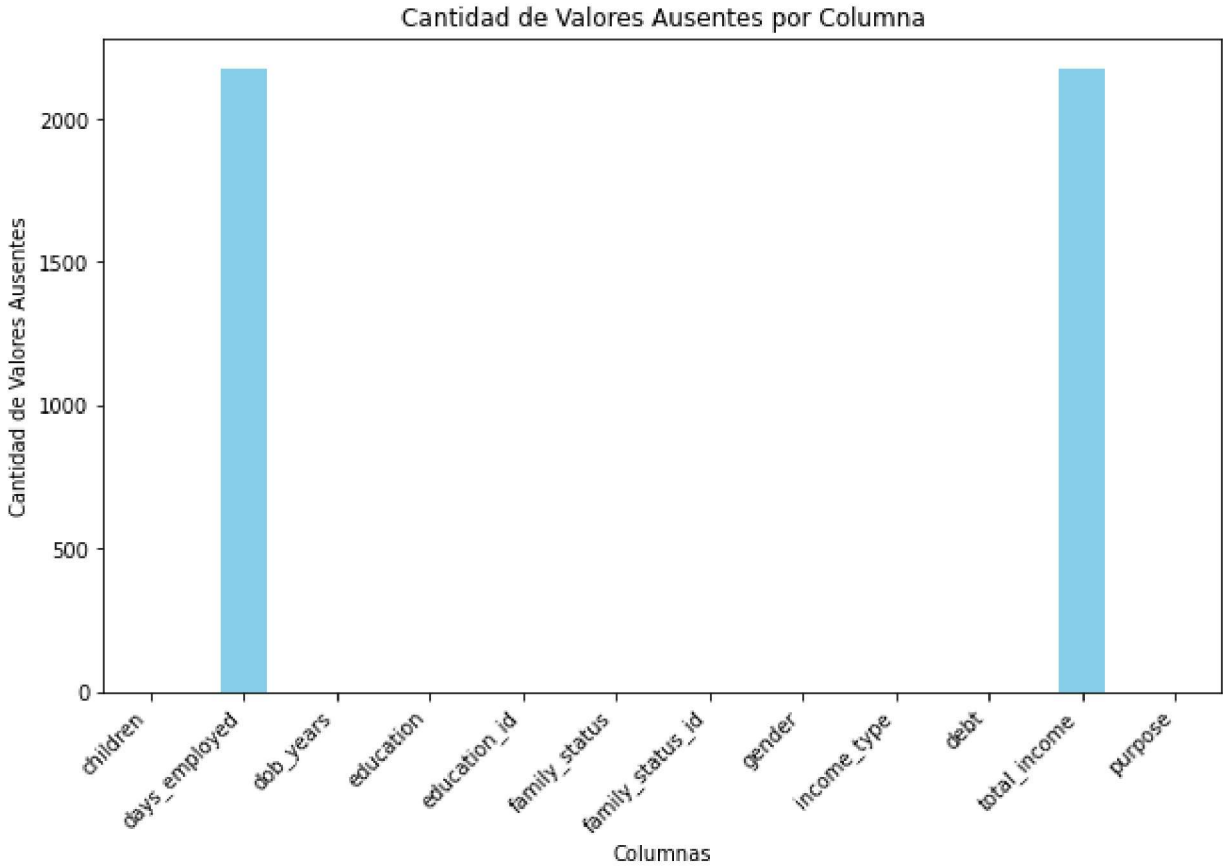

Respuesta del estudiante 1) Si, hay patrones visibles, como llegue a esa conclusion? bueno, es simple, confrontando la grafica de la comprobacion de patrones que esta antes de las $CONCLUSIONES$ y la grafica del mapa de calor que esta encima, podriamos decir que en las columnas 'days_employed' y 'total_income' es donde solamente existen valores ausentes. 2) En la planificacion entiendo que tendre que lidiar directamente con esos valores ausentes, trabajar con los duplicados en otras columnas, problemas de registro en la data, para luego de limpiar la data, y asi usarla como una data representativa real de lo que se quiere investigar en el proyecto.

In [14]:

```
# Paso 1: Crear un DataFrame sin datos nulos
df_not_nan = df.dropna()

# Paso 2: Tablas de frecuencia relativa para variables específicas
variables_to_check = ['income_type', 'education_id', 'gender']

for column in variables_to_check:
    print(f"Tabla de frecuencia relativa para '{column}' con datos nulos:")
    print(df[column].value_counts(normalize=True))
    print(f"Tabla de frecuencia relativa para '{column}' sin datos nulos:")
    print(df_not_nan[column].value_counts(normalize=True))
    print("-------------------------------------")
```

```
Tabla de frecuencia relativa para 'income_type' con datos nulos:
employee                      0.516562
business                      0.236237
retiree                       0.179141
civil servant                 0.067782
```

```
unemployed                     0.000093
entrepreneur                   0.000093
student                        0.000046
paternity / maternity leave    0.000046
Name: income_type, dtype: float64
Tabla de frecuencia relativa para 'income_type' sin datos nulos:
employee                       0.517493
business                       0.236525
retiree                        0.177924
civil servant                  0.067800
unemployed                     0.000103
paternity / maternity leave    0.000052
entrepreneur                   0.000052
student                        0.000052
Name: income_type, dtype: float64
------------------------------------
Tabla de frecuencia relativa para 'education_id' con datos nulos:
1    0.707689
0    0.244367
2    0.034564
3    0.013101
4    0.000279
Name: education_id, dtype: float64
Tabla de frecuencia relativa para 'education_id' sin datos nulos:
1    0.707612
0    0.243708
2    0.034882
3    0.013488
4    0.000310
Name: education_id, dtype: float64
------------------------------------
Tabla de frecuencia relativa para 'gender' con datos nulos:
F      0.661370
M      0.338583
XNA    0.000046
Name: gender, dtype: float64
Tabla de frecuencia relativa para 'gender' sin datos nulos:
F      0.658984
M      0.340964
XNA    0.000052
Name: gender, dtype: float64
------------------------------------
```

Respuesta del estudiante Como podemos ver las diferencias entre los valores con o sin datos nulos es infima, lo que significa que los datos ausentes no tienen una relacion con la variable en cuestion.

Transformación de datos

In [15]:

```python
# Veamos todos los valores en la columna de educación para verificar si será necesario

# Ver todos los valores únicos en la columna de educación
valores_educacion_unicos = df['education'].unique()

# Mostrar los valores únicos y su cantidad
print("\nValores únicos en la columna de educación:")
for valor in valores_educacion_unicos:
    print("-", valor)

# Contar la cantidad de apariciones de cada valor en la columna de educación
```

```
conteo_valores_educacion = df['education'].value_counts()

# Mostrar el conteo de cada valor
print("\nConteo de valores en la columna de educación:")
conteo_valores_educacion
```

```
Valores únicos en la columna de educación:
- bachelor's degree
- secondary education
- Secondary Education
- SECONDARY EDUCATION
- BACHELOR'S DEGREE
- some college
- primary education
- Bachelor's Degree
- SOME COLLEGE
- Some College
- PRIMARY EDUCATION
- Primary Education
- Graduate Degree
- GRADUATE DEGREE
- graduate degree

Conteo de valores en la columna de educación:
```

Out[15]:

```
secondary education    13750
bachelor's degree       4718
SECONDARY EDUCATION      772
Secondary Education      711
some college             668
BACHELOR'S DEGREE        274
Bachelor's Degree        268
primary education        250
Some College              47
SOME COLLEGE              29
PRIMARY EDUCATION         17
Primary Education         15
graduate degree            4
Graduate Degree            1
GRADUATE DEGREE            1
Name: education, dtype: int64
```

In [16]:

```
# Arregla los registros si es necesario

df['education'] = df['education'].str.lower().str.replace('[^\w\s]', '', regex=False)
```

In [17]:

```
# Comprobar todos los valores en la columna para asegurarnos de que los hayamos corregi

# Verificar los valores únicos después de la corrección
valores_educacion_unicos = df['education'].unique()

# Mostrar los valores únicos después de la corrección
print("\nValores únicos en la columna de educación después de la corrección:")
for valor in valores_educacion_unicos:
    print("-", valor)
```

```
Valores únicos en la columna de educación después de la corrección:
- bachelor's degree
- secondary education
- some college
- primary education
- graduate degree
```

Comentario del revisor Buen trabajo.

In [18]:

```python
# Veamos la distribución de los valores en la columna `children`

# Ver todos los valores únicos en la columna `children`
valores_unicos_en_children = df['children'].unique()

# Mostrar los valores únicos y su cantidad
print("\nValores únicos en la columna children:")
for valor in valores_unicos_en_children:
    print("-", valor)

# Contar la cantidad de apariciones de cada valor en la columna `children`
conteo_valores_children = df['children'].value_counts()

# Mostrar el conteo de cada valor
print("\nConteo de valores en la columna children:")
conteo_valores_children
```

```
Valores únicos en la columna children:
- 1
- 0
- 3
- 2
- -1
- 4
- 20
- 5

Conteo de valores en la columna children:
```

Out[18]:

```
 0     14149
 1      4818
 2      2055
 3       330
 20       76
-1        47
 4        41
 5         9
Name: children, dtype: int64
```

In [19]:

```python
# Calcular el conteo de valores -1 y 20 en la columna "children"
conteo_problemas = df['children'].isin([-1, 20]).sum()

# Calcular el porcentaje de datos problemáticos en la columna "children"
porcentaje_problemas = (conteo_problemas / len(df['children'])) * 100

# Mostrar el resultado del porcentaje de datos problemáticos
"Porcentaje de datos problemáticos en la columna 'children': {:.2f}%".format(porcentaje
```

Out[19]:

```
"Porcentaje de datos problemáticos en la columna 'children': 0.57%"
```

Respuesta del estudiante 1) Si, hay anomalias en esta columna. 2) El porcentaje de datos problematicos es un $0.57\,\%$ 3) Esto pudo deberse a errores al llenar el formulario, de parte de los clientes 4) Mi decision seria sustituir estos datos por la mediana, ya que no hara una diferencia representativa, porque son menos del 1% de la data total.

In [20]:

```
# [arregla los datos según tu decisión]

# Calcular la mediana de la columna "children" excluyendo los valores -1 y 20
mediana_children = df.loc[~df['children'].isin([-1, 20]), 'children'].median()

# Reemplazar los valores problemáticos (-1 y 20) por la mediana calculada
df.loc[df['children'] == -1, 'children'] = mediana_children
df.loc[df['children'] == 20, 'children'] = mediana_children

# Convertir los valores en la columna "children" a enteros
df['children'] = df['children'].astype(int)

# Verificar los valores únicos después de la corrección
valores_children_unicos = df['children'].unique()

# Mostrar los valores únicos después de la corrección
print("\nValores únicos en la columna 'children' después de la corrección:")
for valor in valores_children_unicos:
    print("-", valor)
```

```
Valores únicos en la columna 'children' después de la corrección:
- 1
- 0
- 3
- 2
- 4
- 5
```

In [21]:

```
# Comprobar la columna `children` de nuevo para asegurarnos de que todo está arreglado

df['children'].value_counts()
```

Out[21]:

```
0    14272
1     4818
2     2055
3      330
4       41
5        9
Name: children, dtype: int64
```

Comentario del revisor Bien.

In [22]:

```
# Encuentra datos problemáticos en `days_employed`, si existen, y calcula el porcentaje

# Verificar los valores únicos en la columna 'days_employed'
valores_days_employed_unicos = df['days_employed'].unique()

# Identificar valores problemáticos en la columna 'days_employed'
datos_problematicos = df[(df['days_employed'] < 0) | (df['days_employed'] > 36500) | df
```

```
# Calcular el porcentaje de datos problemáticos en la columna 'days_employed'
porcentaje_datos_problematicos = (len(datos_problematicos) / len(df['days_employed']))

# Mostrar el porcentaje de datos problemáticos
"Porcentaje de datos problemáticos en la columna 'days_employed': {:.2f}%".format(porce
```

Out[22]:
```
"Porcentaje de datos problemáticos en la columna 'days_employed': 100.00%"
```

Respuesta del estudiante Aca, como todos los datos o son nulos o superiores a 36500, o son negativos, lo que haremos sera convertir primero todos los datos a positivos, luego trabajaremos los datos superiores a 20000 usando la mediana de la columna, y ya que no eran tantos los superiores a 20000 todo deberia funcionar adecuadamente.

In [23]:
```
# Aborda los valores problemáticos, si existen.

# Convertir los valores negativos de 'days_employed' a positivos
df['days_employed'] = df['days_employed'].abs()

# Reemplazar los valores superiores a 20000 por NaN
df.loc[df['days_employed'] > 20000, 'days_employed'] = np.nan
```

Respuesta del estudiante Con la modificacion del codigo de la manera sugerida quedaria para analizar mas adelante todos esos valores nulos.

In [24]:
```
# Comprueba el resultado - asegúrate de que esté arreglado

df['days_employed'].value_counts()
```

Out[24]:
```
142.276217     1
8615.745089    1
3650.076979    1
2358.122341    1
2569.204627    1
               ..
2152.475526    1
6219.157426    1
5873.586442    1
3355.260838    1
1636.419775    1
Name: days_employed, Length: 15906, dtype: int64
```

In [25]:
```
# Revisa `dob_years` en busca de valores sospechosos y cuenta el porcentaje

# Ver todos los valores únicos en la columna `dob_years`
valores_unicos_en_dob_years = df['dob_years'].unique()

# Mostrar los valores únicos y su cantidad
print("\nValores únicos en la columna dob_years:")
for valor in valores_unicos_en_dob_years:
    print("-", valor)

# Contar la cantidad de apariciones de cada valor en la columna `dob_years`
conteo_valores_en_dob_years = df['dob_years'].value_counts()
```

```python
# Calcular el total de filas en el DataFrame
total_filas = len(df)

# Mostrar el conteo y porcentaje de cada valor
print("\nConteo de valores y porcentaje en la columna dob_years:")
for valor, conteo in conteo_valores_en_dob_years.items():
    porcentaje = (conteo / total_filas) * 100
    print(f"{valor}: {conteo} ({porcentaje:.2f}%)")

# Calcular el porcentaje de datos con valor cero en la columna `dob_years`
conteo_valor_cero = conteo_valores_en_dob_years.get(0, 0)
porcentaje_valor_cero = (conteo_valor_cero / total_filas) * 100
f"\nPorcentaje de datos con valor cero en dob_years: {porcentaje_valor_cero:.2f}%"
```

```
Valores únicos en la columna dob_years:
- 42
- 36
- 33
- 32
- 53
- 27
- 43
- 50
- 35
- 41
- 40
- 65
- 54
- 56
- 26
- 48
- 24
- 21
- 57
- 67
- 28
- 63
- 62
- 47
- 34
- 68
- 25
- 31
- 30
- 20
- 49
- 37
- 45
- 61
- 64
- 44
- 52
- 46
- 23
- 38
- 39
- 51
- 0
- 59
- 29
- 60
- 55
- 58
```

```
- 71
- 22
- 73
- 66
- 69
- 19
- 72
- 70
- 74
- 75

Conteo de valores y porcentaje en la columna dob_years:
35: 617 (2.87%)
40: 609 (2.83%)
41: 607 (2.82%)
34: 603 (2.80%)
38: 598 (2.78%)
42: 597 (2.77%)
33: 581 (2.70%)
39: 573 (2.66%)
31: 560 (2.60%)
36: 555 (2.58%)
44: 547 (2.54%)
29: 545 (2.53%)
30: 540 (2.51%)
48: 538 (2.50%)
37: 537 (2.49%)
50: 514 (2.39%)
43: 513 (2.38%)
32: 510 (2.37%)
49: 508 (2.36%)
28: 503 (2.34%)
45: 497 (2.31%)
27: 493 (2.29%)
56: 487 (2.26%)
52: 484 (2.25%)
47: 480 (2.23%)
54: 479 (2.23%)
46: 475 (2.21%)
58: 461 (2.14%)
57: 460 (2.14%)
53: 459 (2.13%)
51: 448 (2.08%)
59: 444 (2.06%)
55: 443 (2.06%)
26: 408 (1.90%)
60: 377 (1.75%)
25: 357 (1.66%)
61: 355 (1.65%)
62: 352 (1.64%)
63: 269 (1.25%)
64: 265 (1.23%)
24: 264 (1.23%)
23: 254 (1.18%)
65: 194 (0.90%)
66: 183 (0.85%)
22: 183 (0.85%)
67: 167 (0.78%)
21: 111 (0.52%)
0: 101 (0.47%)
68: 99 (0.46%)
69: 85 (0.39%)
70: 65 (0.30%)
71: 58 (0.27%)
20: 51 (0.24%)
```

```
72: 33 (0.15%)
19: 14 (0.07%)
73: 8 (0.04%)
74: 6 (0.03%)
75: 1 (0.00%)
```

Out[25]: '\nPorcentaje de datos con valor cero en dob_years: 0.47%'

Respuesta del estudiante Bueno, como podemos observar tenemos clientes donde se muestra como edad el numero 0, 101 clientes para un 0.47%, obviamente esa no es una edad valida y nos lleva a la necesidad de corregir estos datos, para corregirlos utilizaremos la mediana, ya que esta proporcionará una estimación más robusta de la edad típica en el conjunto de datos. La mediana no se verá afectada por valores atípicos y será menos susceptible a errores o variaciones en los datos.

In [26]:

```
# Resuelve los problemas en la columna `dob_years`, si existen

# Calcular la mediana de la columna 'dob_years' excluyendo los valores 0
mediana_dob_years = df[df['dob_years'] > 0]['dob_years'].median()

# Reemplazar los valores 0 en 'dob_years' por la mediana calculada
df.loc[df['dob_years'] == 0, 'dob_years'] = mediana_dob_years
```

Comentario del revisor Buen trabajo.

In [27]:

```
# Comprueba el resultado - asegúrate de que esté arreglado
df['dob_years'].value_counts()
```

Out[27]:

```
35.0    617
43.0    614
40.0    609
41.0    607
34.0    603
38.0    598
42.0    597
33.0    581
39.0    573
31.0    560
36.0    555
44.0    547
29.0    545
30.0    540
48.0    538
37.0    537
50.0    514
32.0    510
49.0    508
28.0    503
45.0    497
27.0    493
56.0    487
52.0    484
47.0    480
54.0    479
46.0    475
58.0    461
```

```
57.0    460
53.0    459
51.0    448
59.0    444
55.0    443
26.0    408
60.0    377
25.0    357
61.0    355
62.0    352
63.0    269
64.0    265
24.0    264
23.0    254
65.0    194
66.0    183
22.0    183
67.0    167
21.0    111
68.0     99
69.0     85
70.0     65
71.0     58
20.0     51
72.0     33
19.0     14
73.0      8
74.0      6
75.0      1
Name: dob_years, dtype: int64
```

In [28]:

```
# Veamos los valores de la columna

# Verificar los valores únicos en la columna 'family_status'
valores_unicos_family_status = df['family_status'].unique()

# Mostrar los valores únicos
print("Valores únicos en la columna 'family_status':")
print(valores_unicos_family_status)

# Contar la cantidad de ocurrencias de cada valor en la columna 'family_status'
conteo_family_status = df['family_status'].value_counts()

# Mostrar el conteo de ocurrencias
print("\nConteo de ocurrencias en la columna 'family_status':")
print(conteo_family_status)

# Contar la cantidad de valores nulos en la columna 'family_status'
valores_nulos_family_status = df['family_status'].isnull().sum()

# Mostrar la cantidad de valores nulos
"Cantidad de valores nulos en la columna 'family_status':", valores_nulos_family_status
```

```
Valores únicos en la columna 'family_status':
['married' 'civil partnership' 'widow / widower' 'divorced' 'unmarried']

Conteo de ocurrencias en la columna 'family_status':
married              12380
civil partnership     4177
unmarried             2813
divorced              1195
```

```
widow / widower        960
Name: family_status, dtype: int64
```

Out[28]:
```
("Cantidad de valores nulos en la columna 'family_status':", 0)
```

In [29]:
```
# Aborda los valores problemáticos en `family_status`, si existen
```

Respuesta del estudiante Ya que esta columna esta 100% correcta y sin valores nulos solo desplegare el resultado en la celda siguiente y seguire adelante.

In [30]:
```
# Comprueba el resultado - asegúrate de que esté arreglado
df['family_status'].value_counts()
```

Out[30]:
```
married              12380
civil partnership     4177
unmarried             2813
divorced              1195
widow / widower        960
Name: family_status, dtype: int64
```

Respuesta del estudiante Como podemos aprecia en el resultado del codigo que esta debajo, en la columna existe un valor llamado XNA, lo cual no representa un valor de genero real, para corregir este detalle reemplazaremos ese dato por el valor mas frecuente de esta columna, en este caso seria F y ya que es 1 solo valor tampoco variara demasiado la estadistica.

In [31]:
```
# Veamos los valores en la columna

# Verificar los valores únicos en la columna 'gender'
valores_unicos_en_gender = df['gender'].unique()

# Mostrar los valores únicos
print("Valores únicos en la columna 'gender':")
print(valores_unicos_en_gender)

# Contar la cantidad de ocurrencias de cada valor en la columna 'gender'
conteo_de_gender = df['gender'].value_counts()

# Mostrar el conteo de ocurrencias
print("\nConteo de ocurrencias en la columna 'gender':")
print(conteo_de_gender)

# Contar la cantidad de valores nulos en la columna 'gender'
valores_nulos_en_gender = df['gender'].isnull().sum()

# Mostrar la cantidad de valores nulos
"Cantidad de valores nulos en la columna 'gender':", valores_nulos_en_gender
```

```
Valores únicos en la columna 'gender':
['F' 'M' 'XNA']

Conteo de ocurrencias en la columna 'gender':
F      14236
M       7288
```

```
XNA        1
Name: gender, dtype: int64
```

Out[31]:
```
("Cantidad de valores nulos en la columna 'gender':", 0)
```

In [32]:
```python
# Aborda los valores problemáticos, si existen

# Contar la cantidad de ocurrencias de cada valor en la columna 'gender'
conteo_de_gender = df['gender'].value_counts()

# Mostrar los valores únicos y el conteo de ocurrencias
print("Valores únicos en la columna 'gender':")
print(df['gender'].unique())
print("\nConteo de ocurrencias en la columna 'gender':")
print(conteo_de_gender)

# Reemplazar el valor 'XNA' con el valor más frecuente, en este caso, 'F'
df['gender'] = df['gender'].replace('XNA', 'F')
```

```
Valores únicos en la columna 'gender':
['F' 'M' 'XNA']

Conteo de ocurrencias en la columna 'gender':
F      14236
M       7288
XNA        1
Name: gender, dtype: int64
```

In [33]:
```python
# Comprueba el resultado - asegúrate de que esté arreglado

df['gender'].value_counts()
```

Out[33]:
```
F    14237
M     7288
Name: gender, dtype: int64
```

In [34]:
```python
# Veamos los valores en la columna

# Verificar los valores únicos en la columna 'income_type'
valores_unicos_en_income_type = df['income_type'].unique()

# Mostrar los valores únicos
print("Valores únicos en la columna 'income_type':")
print(valores_unicos_en_income_type)

# Contar la cantidad de ocurrencias de cada valor en la columna 'income_type'
conteo_de_income_type = df['income_type'].value_counts()

# Mostrar el conteo de ocurrencias
print("\nConteo de ocurrencias en la columna 'income_type':")
print(conteo_de_income_type)

# Contar la cantidad de valores nulos en la columna 'gender'
valores_nulos_en_income_type = df['income_type'].isnull().sum()

# Mostrar la cantidad de valores nulos
"Cantidad de valores nulos en la columna 'income_type':", valores_nulos_en_income_type
```

```
Valores únicos en la columna 'income_type':
['employee' 'retiree' 'business' 'civil servant' 'unemployed'
 'entrepreneur' 'student' 'paternity / maternity leave']

Conteo de ocurrencias en la columna 'income_type':
employee                       11119
business                        5085
retiree                         3856
civil servant                   1459
unemployed                         2
entrepreneur                       2
student                            1
paternity / maternity leave        1
Name: income_type, dtype: int64
```

Out[34]:
```
("Cantidad de valores nulos en la columna 'income_type':", 0)
```

Respuesta del estudiante Como podemos aprecia en el resultado del codigo que tenemos arriba, hay ciertos valores que son minimos, como son: $u \neq mployed$, $entrepre \neq ur$, $student$ y $paternit\frac{y}{m}aternity \leq ave$, si tomamos en consideracion que son unos valores que no son de gran interes para nosotros ya que no inciden lo suficiente en los resultados, podemos agruparlos en un nuevo renglon llamado $other$ y asi tenemos menos variables presentes y la informacion esta menos disgregada.

In [35]:
```
# Aborda los valores problemáticos, si existen

# Agrupar los valores poco frecuentes en la categoría 'other'
valores_poco_frecuentes = ['unemployed', 'entrepreneur', 'student', 'paternity / matern
df['income_type'] = df['income_type'].replace(valores_poco_frecuentes, 'other')
```

In [36]:
```
# Comprueba el resultado - asegúrate de que esté arreglado

df['income_type'].value_counts()
```

Out[36]:
```
employee         11119
business          5085
retiree           3856
civil servant     1459
other                6
Name: income_type, dtype: int64
```

Respuesta del estudiante En el resultado del codigo que esta debajo podemos aprecia que tenemos en el dataframe, 71 duplicados, esto representa un 0.097% de nuestra data total, al estos datos duplicados no ser una cantidad representativa de la totalidad de datos procedere a borrarlos, para no tener esa duplicidad que no nos provee informacion util.

In [37]:
```
# Comprobar los duplicados

# Verificar si hay duplicados en el DataFrame
duplicados = df.duplicated()

# Contar la cantidad total de duplicados
total_duplicados = duplicados.sum()
```

```
# Mostrar el número total de duplicados
print("Cantidad total de duplicados:", total_duplicados)

# Mostrar las filas duplicadas si las hay
if total_duplicados > 0:
    print("\nFilas duplicadas:")
    df[duplicados]
```

```
Cantidad total de duplicados: 71

Filas duplicadas:
```

In [38]:

```
# Aborda los duplicados, si existen

# Eliminar los duplicados del DataFrame y resetear el índice
df = df.drop_duplicates(ignore_index=True)
```

Respuesta del estudiante Aca resetee el indice como requeria, usando el ign or $e_{\in}dex = True$.

In [39]:

```
# Última comprobación para ver si tenemos duplicados

# Verificar si hay duplicados en el DataFrame
duplicados = df.duplicated()

# Contar la cantidad total de duplicados
total_duplicados = duplicados.sum()

# Mostrar el número total de duplicados
print("Cantidad total de duplicados:", total_duplicados)

# Mostrar las filas duplicadas si las hay
if total_duplicados > 0:
    print("\nFilas duplicadas:")
    df[duplicados]
```

```
Cantidad total de duplicados: 0
```

In [40]:

```
# Comprueba el tamaño del conjunto de datos que tienes ahora, después de haber ejecutad


# Contar el número de filas después de eliminar los duplicados
filas_despues = len(df)

# Mostrar el número de filas después de la eliminación de duplicados
print("Número de filas después de eliminar duplicados:", filas_despues)

# Mostrar el tamaño del conjunto de datos después de eliminar los duplicados (número de
print("\nTamaño del conjunto de datos después de eliminar duplicados:")
df.shape
```

```
Número de filas después de eliminar duplicados: 21454

Tamaño del conjunto de datos después de eliminar duplicados:
```

Out[40]:
```
(21454, 12)
```

Respuesta del estudiante En este conjunto de datos. Primero aborde la columna $education$ a la cual le di un tratamiento para poner los valores todos en minuscula y asi tener menos variedad de valores y la informacion es mas entendible. En la columna $\chi ldren$ teniamos datos negativos y con cantidades irreales, estos datos fueron sustituidos por la mediana, ya que asi no incidiremos demasiado en la data, pero podremos proveer una informacion suficientemente acertada. Luego en la columna $days_employed$ pudimos ver que todos los datos tenian problemas, o eran datos nulos, o eran datos superiores a 36500 (lo cual representa 100 años) o eran datos negativos, lo que primero se hizo fue convertir esos datos a positivos, luego trabajar los datos superiores a 20000, y a esos juntos con los datos nulos los cambiamos por la mediana de la columna en cuestion, hemos estado usando la mediana ya que las columnas tienen valores asimetricos y no queremos incidir demasiado en los resultados al tratar la data. En la columna dob_years encontramos 101 clientes con edad de valor 0, lo cual es irreal, asi que como seguimos trabajando datos asimetricos y no queremos incidir demasiado en los resultados volvimos a usar la mediana para corregir los 101 valores incorrectos. La columna $family_status$ estaba correcta completamente, asi que no se le tuvo que dar ningun tipo de tratamiento. La columna de $\geq nder$ tenia 1 valor atipico llamado XNA, el cual fue sutituido por el valor que mas se repite, en este caso F, asi pasamos solo a tener solo valores que realmente representan el genero. Luego en la columna $\in come_type$ nos encontramos con que a pesar que no teniamos valores nulos, si teniamos algunos valores atipicos minimos como fueron: $u \neq mployed$, $entrepre \neq ur$, $student$ y $paternit\frac{y}{m}aternity \leq ave$, los cuales fueron agrupados en un nuevo renglon llamado $other$, para asi tener una data mas entendible y menos disgregada. Aparte tambien trabajamos los duplicados en el dataframe completo los cuales representaban un 0.097% de la data, al no ser representativos simplemente decidi borrarlos para tener una data mas acertada y concisa. El porcentaje de cambios que se hizo en el dataframe no sobrepasa un $5\ \%$ de cambios, asi que no representa una amenaza a la investigacion que se esta llevando acabo. Solo restaria trabajar con la columna $\rightarrow tal_{\in} come$.

Trabajar con valores ausentes

Respuesta del estudiante Ya que solo pude observar correlaciones entre las columnas $education$ respecto a $education$ y de $family_status$ respecto de $family_status$, utilizare estos 2 diccionarios para poder tener mas facilidad al trabajar las conclusiones del trabajo de investigacion ya que podrian usarse como parametros guia y para poner un ejemplo podrian mostrar una relacion entre los pagos, la educacion del cliente y su estatus marital.

In [41]:
```
# Encuentra los diccionarios

# Realizar una copia del DataFrame
```

```
df_copy = df.copy()

# Realizar el mapeo entre 'education' y 'education_id' mediante un diccionario
education_mapping = {
    "bachelor's degree": 0,
    "secondary education": 1,
    "some college": 2,
    "primary education": 3,
    "graduate degree": 4
}

# Crear una nueva columna 'education_mapped' en la copia que contiene los valores de 'e
df_copy['education_mapped'] = df_copy['education'].map(education_mapping)

# Realizar el mapeo entre 'family_status' y 'family_status_id' mediante un diccionario
family_status_mapping = {
    "married": 0,
    "civil partnership": 1,
    "unmarried": 2,
    "divorced": 3,
    "widow / widower": 4
}

# Crear una nueva columna 'family_status_mapped' en la copia que contiene los valores d
df_copy['family_status_mapped'] = df_copy['family_status'].map(family_status_mapping)

# Mostrar la copia del DataFrame con las columnas 'education_mapped' y 'family_status_m
print("\nCopia del DataFrame con las columnas 'education_mapped' y 'family_status_mappe
df_copy[['education', 'education_mapped', 'family_status', 'family_status_mapped']]
```

```
Copia del DataFrame con las columnas 'education_mapped' y 'family_status_mapped':
```

Out[41]:

	education	education_mapped	family_status	family_status_mapped
0	bachelor's degree	0	married	0
1	secondary education	1	married	0
2	secondary education	1	married	0
3	secondary education	1	married	0
4	secondary education	1	civil partnership	1
...	...	...	...	...
21449	secondary education	1	civil partnership	1
21450	secondary education	1	married	0
21451	secondary education	1	civil partnership	1
21452	secondary education	1	married	0
21453	secondary education	1	married	0

21454 rows × 4 columns

Restaurar valores ausentes en `total_income`

Respuesta del estudiante Las unicas columnas con valores ausentes ahora mismo son $days_{e}mployed$ y $\rightarrow tal_{\in}come$, ya que estan correlacionadas y la cantidad de data de cada columna que afectan estos valores nulos es de un 9.8% en la cantidad total de valores de la columna digase 2103 valores por columna, utilizaremos la mediana como valor mas seguro para corregir este problema.

In [42]:

```
# Vamos a escribir una función que calcule la categoría de edad

def get_age_category(age):
    if age < 30:
        return 'Joven'
    elif age < 45:
        return 'Adulto Joven'
    elif age < 60:
        return 'Adulto Medio'
    else:
        return 'Adulto Mayor'

# Crear una copia del DataFrame
df_copy = df.copy()

# Crear la nueva columna 'age_category' usando la función en la copia del DataFrame
df_copy['age_category'] = df_copy['dob_years'].apply(get_age_category)
```

In [43]:

```
# Prueba si la función funciona bien

# Mostrar el DataFrame con la nueva columna 'age_category'
df_copy[['dob_years', 'age_category']]
```

Out[43]:

	dob_years	age_category
0	42.0	Adulto Joven
1	36.0	Adulto Joven
2	33.0	Adulto Joven
3	32.0	Adulto Joven
4	53.0	Adulto Medio
...	...	...
21449	43.0	Adulto Joven
21450	67.0	Adulto Mayor
21451	38.0	Adulto Joven
21452	38.0	Adulto Joven
21453	40.0	Adulto Joven

21454 rows × 2 columns

In [44]:

```
# Crear una nueva columna basada en la función

def get_age_category(age):
    if age < 18:
        return 'Menor de edad'
    elif 18 <= age < 30:
        return 'Joven'
    elif 30 <= age < 45:
        return 'Adulto joven'
    elif 45 <= age < 60:
        return 'Adulto maduro'
    else:
        return 'Adulto mayor'

# Crear una copia de la copia del DataFrame para evitar el problema de SettingWithCopyW
df_copy = df.copy()

# Crear una nueva columna 'age_category' usando la función get_age_category
df_copy['age_category'] = df_copy['dob_years'].apply(get_age_category)
```

In [45]:

```
# Comprobar cómo los valores en la nueva columna

# Mostrar el DataFrame con la nueva columna 'age_category'
df_copy[['dob_years', 'age_category']]
```

Out[45]:

	dob_years	age_category
0	42.0	Adulto joven
1	36.0	Adulto joven
2	33.0	Adulto joven
3	32.0	Adulto joven
4	53.0	Adulto maduro
...	...	...
21449	43.0	Adulto joven
21450	67.0	Adulto mayor
21451	38.0	Adulto joven
21452	38.0	Adulto joven
21453	40.0	Adulto joven

21454 rows × 2 columns

In [46]:

```
# Crea una tabla sin valores ausentes y muestra algunas de sus filas para asegurarte de

# Asegurarnos de que la columna 'age_category' existe en el DataFrame
if 'age_category' not in df.columns:
    # Crear la columna 'age_category' utilizando la función get_age_category()
    df['age_category'] = df['dob_years'].apply(get_age_category)
```

```
# Crear una copia del DataFrame para evitar modificar los datos originales
df_cleaned = df.copy()

# Imputar los valores nulos en la columna "total_income" usando la función fill_missing_
df_cleaned['total_income'] = df_cleaned['total_income'].fillna(df_cleaned.groupby(['age

# Verificar el número de entradas en las columnas
total_income_count = df_cleaned['total_income'].count()
other_column_counts = df_cleaned.dropna(axis=1).count()

# Mostrar el número de valores en la columna "total_income"
print("Número de valores en la columna 'total_income':", total_income_count)

# Mostrar el número de valores en otras columnas
print("\nNúmero de valores en otras columnas:")
print(other_column_counts)

# Verificar si los conteos coinciden
if total_income_count == other_column_counts.min():
    print("\nEl número total de valores en la columna 'total_income' coincide con los n
else:
    print("\nEl número total de valores en la columna 'total_income' NO coincide con lo
```

```
Número de valores en la columna 'total_income': 21454

Número de valores en otras columnas:
children            21454
dob_years           21454
education           21454
education_id        21454
family_status       21454
family_status_id    21454
gender              21454
income_type         21454
debt                21454
total_income        21454
purpose             21454
age_category        21454
dtype: int64

El número total de valores en la columna 'total_income' coincide con los números de valo
res en otras columnas.
```

In [47]:

```
# Examina los valores medios de los ingresos en función de los factores que identificas

# Verificar si la columna 'age_category' existe en el DataFrame
if 'age_category' not in df_cleaned.columns:
    # Crear la columna 'age_category' utilizando la función get_age_category()
    df_cleaned['age_category'] = df_cleaned['dob_years'].apply(get_age_category)

# Agrupar los datos por la categoría de edad y calcular el ingreso promedio en cada gru
income_by_age_category = df_cleaned.groupby('age_category')['total_income'].mean()

# Agrupar los datos por el nivel de educación y calcular el ingreso promedio en cada gr
income_by_education = df_cleaned.groupby('education')['total_income'].mean()

# Agrupar los datos por el estado civil y calcular el ingreso promedio en cada grupo
income_by_family_status = df_cleaned.groupby('family_status')['total_income'].mean()

# Mostrar los resultados
print("Ingreso promedio por categoría de edad:")
```

```
print(income_by_age_category)

print("\nIngreso promedio por nivel de educación:")
print(income_by_education)

print("\nIngreso promedio por estado civil:")
income_by_family_status
```

```
Ingreso promedio por categoría de edad:
age_category
Adulto joven     28098.062721
Adulto maduro    26353.032500
Adulto mayor     22706.565791
Joven            25274.729120
Name: total_income, dtype: float64

Ingreso promedio por nivel de educación:
education
bachelor's degree      32656.974978
graduate degree        27960.024667
primary education      20905.934796
secondary education    24317.332298
some college           28809.126958
Name: total_income, dtype: float64

Ingreso promedio por estado civil:
```

Out[47]:

```
family_status
civil partnership    26369.482922
divorced             26855.422737
married              26713.025967
unmarried            26675.834721
widow / widower      22696.383450
Name: total_income, dtype: float64
```

In [48]:

```
# Examina los valores medianos de los ingresos en función de los factores que identific

# Verificar si la columna 'age_category' existe en el DataFrame
if 'age_category' not in df_cleaned.columns:
    # Crear la columna 'age_category' utilizando la función get_age_category()
    df_cleaned['age_category'] = df_cleaned['dob_years'].apply(get_age_category)

# Agrupar los datos por la categoría de edad y calcular la mediana del ingreso en cada
median_income_by_age_category = df_cleaned.groupby('age_category')['total_income'].medi

# Agrupar los datos por el nivel de educación y calcular la mediana del ingreso en cada
median_income_by_education = df_cleaned.groupby('education')['total_income'].median()

# Agrupar los datos por el estado civil y calcular la mediana del ingreso en cada grupo
median_income_by_family_status = df_cleaned.groupby('family_status')['total_income'].me

# Mostrar los resultados
print("Mediana del ingreso por categoría de edad:")
print(median_income_by_age_category)

print("\nMediana del ingreso por nivel de educación:")
print(median_income_by_education)

print("\nMediana del ingreso por estado civil:")
median_income_by_family_status
```

```
Mediana del ingreso por categoría de edad:
age_category
Adulto joven     24019.7405
Adulto maduro    22194.6005
Adulto mayor     19363.7220
Joven            22373.6910
Name: total_income, dtype: float64

Mediana del ingreso por nivel de educación:
education
bachelor's degree      28593.7795
graduate degree        25161.5835
primary education      18772.3095
secondary education    22042.6715
some college           25710.1140
Name: total_income, dtype: float64

Mediana del ingreso por estado civil:
```

Out[48]:

```
family_status
civil partnership    23050.3285
divorced             22879.7325
married              23032.1150
unmarried            22717.5370
widow / widower      20527.7540
Name: total_income, dtype: float64
```

Respuesta del estudiante Las caracteristicas que definen mejor los ingresos son $a \geq_c ateg$ or y, $education$ y $family_status$, porque estas caracteristicas los definen mejor, es simple, mientras mayor $education$ se suele tener un income mayor, lo cual queda evidenciado en la data, tambien podemos ver que en la mediana edad que figura en $a \geq_c ateg$ or y el cliente recibe mas dividendos y que los clientes con un $family_status$ de divorciados tienen mejor income. Al final decidi utilizar la mediana ya que habia valores atipicos y la mediana es la que me brinda mas seguridad de que el resultado final no va a cambiar demasiado los resultados.

Respuesta del estudiante La funcion fue eliminada, ya que no sera util.

In [49]:

```
# Contar la cantidad de valores nulos en la columna "total_income"

valores_nulos_total_income = df_cleaned['total_income'].isnull().sum()
print("Cantidad de valores nulos en la columna 'total_income':", valores_nulos_total_in
```

```
Cantidad de valores nulos en la columna 'total_income': 0
```

In [50]:

```
# Aplícalo a cada fila

# Completar los valores ausentes en la columna "total_income" usando la función fill_mi
df_cleaned['total_income'] = df_cleaned['total_income'].fillna(df_cleaned.groupby(['age
```

In [51]:

```
# Comprueba si tenemos algún error

# Contar la cantidad de valores nulos en la columna "total_income" después de completar
valores_nulos_total_income_despues = df_cleaned['total_income'].isnull().sum()
print("Cantidad de valores nulos en la columna 'total_income' después de completar:", v
```

```
Cantidad de valores nulos en la columna 'total_income' después de completar: 0
```

In [52]:

```
# Reemplazar los valores ausentes si hay algún error
```

In [53]:

```
# Comprobar el número de entradas en las columnas

# Asegurarnos de que la columna 'age_category' existe en el DataFrame
if 'age_category' not in df.columns:
    # Crear la columna 'age_category' utilizando la función get_age_category()
    df['age_category'] = df['dob_years'].apply(get_age_category)

# Crear una copia del DataFrame para evitar modificar los datos originales
df_cleaned = df.copy()

# Imputar los valores nulos en la columna "total_income" usando la función fill_missing_
df_cleaned['total_income'] = df_cleaned['total_income'].fillna(df_cleaned.groupby(['age

# Verificar el número de entradas en las columnas
total_income_count = df_cleaned['total_income'].count()
other_column_counts = df_cleaned.dropna(axis=1).count()

# Mostrar el número de valores en la columna "total_income"
print("Número de valores en la columna 'total_income':", total_income_count)

# Mostrar el número de valores en otras columnas
print("\nNúmero de valores en otras columnas:")
print(other_column_counts)

# Verificar si los conteos coinciden
if total_income_count == other_column_counts.min():
    print("\nEl número total de valores en la columna 'total_income' coincide con los n
else:
    print("\nEl número total de valores en la columna 'total_income' NO coincide con lo
```

```
Número de valores en la columna 'total_income': 21454

Número de valores en otras columnas:
children            21454
dob_years           21454
education           21454
education_id        21454
family_status       21454
family_status_id    21454
gender              21454
income_type         21454
debt                21454
total_income        21454
purpose             21454
age_category        21454
dtype: int64

El número total de valores en la columna 'total_income' coincide con los números de valo
res en otras columnas.
```

Restaurar valores en `days_employed`

Respuesta del estudiante Como pude observar la correlacion usada en $\rightarrow tal_{\in} come$ funciona correctamente tambien para esta columna, asi que, aca tendremos en cuenta $a \geq_c ateg \text{ or } y$, $education$ y $family_s tatus$ por igual.

In [54]:

```
# Distribución de las medianas de `days_employed` en función de los parámetros identifi

# Crear una copia del DataFrame para trabajar con ella
df_cleaned = df.copy()

# Definir la función para calcular la categoría de edad
def get_age_category(age):
    if age < 25:
        return 'Joven'
    elif age < 35:
        return 'Adulto joven'
    elif age < 55:
        return 'Adulto maduro'
    else:
        return 'Adulto mayor'

# Crear la columna 'age_category' utilizando la función get_age_category
df_cleaned['age_category'] = df_cleaned['dob_years'].apply(get_age_category)

# Calcular la mediana de 'days_employed' excluyendo nulos y valores superiores a 20000
mediana_days_employed = df_cleaned.loc[(~df_cleaned['days_employed'].isnull()) & (df_cl

# Reemplazar valores negativos por su valor absoluto y valores superiores a 20000 por l
df_cleaned['days_employed'] = df_cleaned['days_employed'].apply(lambda x: abs(x) if x <

# Crear un DataFrame para la distribución de medianas de 'days_employed' en función de
df_age_category_median = df_cleaned.groupby('age_category')['days_employed'].median().r

# Mostrar el DataFrame resultante
print("Distribución de las medianas de 'days_employed' en función de la categoría de ed
df_age_category_median
```

```
Distribución de las medianas de 'days_employed' en función de la categoría de edad:
```

Out[54]:

	age_category	days_employed
0	Adulto joven	1284.275365
1	Adulto maduro	1960.942262
2	Adulto mayor	2476.155472
3	Joven	744.279198

In [55]:

```
# Distribución de las medias de `days_employed` en función de los parámetros identifica

# Crear una copia del DataFrame para trabajar con ella
df_cleaned = df.copy()

# Crear la columna 'age_category' utilizando la función get_age_category
df_cleaned['age_category'] = df_cleaned['dob_years'].apply(get_age_category)

# Calcular la media de 'days_employed' excluyendo nulos y valores superiores a 20000
```

```
media_days_employed = df_cleaned.loc[(~df_cleaned['days_employed'].isnull()) & (df_clea

# Reemplazar valores negativos por su valor absoluto y valores superiores a 20000 por l
df_cleaned['days_employed'] = df_cleaned['days_employed'].apply(lambda x: abs(x) if x <

# Crear un DataFrame para la distribución de medias de 'days_employed' en función de la
df_age_category_mean = df_cleaned.groupby('age_category')['days_employed'].mean().reset

# Mostrar el DataFrame resultante
print("Distribución de las medias de 'days_employed' en función de la categoría de edad
df_age_category_mean
```

```
Distribución de las medias de 'days_employed' en función de la categoría de edad:
```

Out[55]:

	age_category	days_employed
0	Adulto joven	1586.946577
1	Adulto maduro	2665.848917
2	Adulto mayor	3588.744141
3	Joven	854.010820

Respuesta del estudiante Aca por igual como tenemos valores atipicos utilizaremos la mediana, para conservar con mayor integridad la data y obtener unos resultados imparciales.

In [56]:

```
# Escribamos una función que calcule medias o medianas (dependiendo de tu decisión) seg

def calculate_statistic(df, column_of_interest, identified_parameter, statistic='mean')
    """
    Calcula la media o mediana de una columna de interés según un parámetro identificad

    Parámetros:
        df (DataFrame): El DataFrame que contiene los datos.
        column_of_interest (str): El nombre de la columna de interés para calcular la m
        identified_parameter (str): El nombre del parámetro identificado para agrupar l
        statistic (str, opcional): El tipo de estadística a calcular. Puede ser 'mean'
                                   Por defecto, se utiliza 'mean'.

    Retorna:
        DataFrame: Un DataFrame con la media o mediana de la columna de interés para ca
    """
    if statistic not in ['mean', 'median']:
        raise ValueError("El valor de 'statistic' debe ser 'mean' o 'median'.")

    # Calcular la media o mediana según el parámetro identificado
    if statistic == 'mean':
        result = df.groupby(identified_parameter)[column_of_interest].mean().reset_inde
    else:
        result = df.groupby(identified_parameter)[column_of_interest].median().reset_in

    return result
```

In [57]:

```
# Comprueba que la función funciona

# Calcular la media de 'total_income' según la categoría de edad
```

```
income_by_age_category_mean = calculate_statistic(df_cleaned, 'total_income', 'age_cate

# Calcular la mediana de 'total_income' según el nivel de educación
income_by_education_median = calculate_statistic(df_cleaned, 'total_income', 'education

# Calcular la media de 'total_income' según el estado civil
income_by_family_status_mean = calculate_statistic(df_cleaned, 'total_income', 'family_
```

In [58]:

```
# Aplicar la función al income_type

# Calcular la media de 'total_income' según el tipo de ingreso
income_by_income_type_mean = calculate_statistic(df_cleaned, 'total_income', 'income_ty

# Calcular la mediana de 'total_income' según el tipo de ingreso
income_by_income_type_median = calculate_statistic(df_cleaned, 'total_income', 'income_
```

In [59]:

```
# Comprueba si la función funcionó

# Imprimir el DataFrame con la media del ingreso por tipo de ingreso
print("Media del ingreso por tipo de ingreso:")
print(income_by_income_type_mean)

# Imprimir el DataFrame con la mediana del ingreso por tipo de ingreso
print("\nMediana del ingreso por tipo de ingreso:")
income_by_income_type_median
```

```
Media del ingreso por tipo de ingreso:
     income_type  total_income
0       business  32386.793835
1  civil servant  27343.729582
2       employee  25820.841683
3          other  29243.949000
4        retiree  21940.394503

Mediana del ingreso por tipo de ingreso:
```

Out[59]:

	income_type	total_income
0	business	27577.2720
1	civil servant	24071.6695
2	employee	22815.1035
3	other	15712.2600
4	retiree	18962.3180

In [60]:

```
# Reemplazar valores ausentes

# Crear un diccionario que mapee las categorías en 'income_type' del DataFrame original
income_type_order = ['employee', 'retiree', 'business', 'civil servant', 'other']
income_type_median_dict = dict(zip(income_by_income_type_median['income_type'], income_

# Función para reemplazar los valores nulos en 'days_employed' usando el diccionario de
def replace_missing_days_employed(days_employed, income_type, income_type_median_dict):
    if pd.isnull(days_employed):
        # Eliminar espacios adicionales y convertir a minúsculas
        income_type_cleaned = income_type.strip().lower()
```

```
        return income_type_median_dict[income_type_cleaned]
    else:
        return days_employed

# Reemplazar los valores nulos en 'days_employed' usando la función 'replace_missing_da
df_cleaned['days_employed'] = df_cleaned.apply(lambda row: replace_missing_days_employe
```

Respuesta del estudiante Agregue la caja de codigo de debajo para demostrar que el numero total de valores coincide en todas las columnas, aparte, podemos observar en el codigo que esta debajo de este que no hay valores nulos en ninguna de las columnas presentes.

In [61]:

```
# Comprobar si el número de valores en 'days_employed' coincide con el número en otras

# Verificar el número de valores no nulos en la columna 'days_employed'
count_days_employed = df_cleaned['days_employed'].notnull().sum()

# Verificar el número de valores no nulos en las otras columnas
count_other_columns = df_cleaned.dropna(axis=1).shape[0]

# Imprimir la cantidad de valores no nulos en la columna 'days_employed'
print("Cantidad de valores no nulos en la columna 'days_employed':", count_days_employe

# Imprimir la cantidad de valores no nulos en las otras columnas
print("Cantidad de valores no nulos en otras columnas:", count_other_columns)
```

```
Cantidad de valores no nulos en la columna 'days_employed': 21454
Cantidad de valores no nulos en otras columnas: 21454
```

In [62]:

```
# Comprueba las entradas en todas las columnas: asegúrate de que hayamos corregido todo

# Crear una copia del DataFrame para evitar modificar los datos originales
df_cleaned = df.copy()

# Imputar los valores nulos en la columna 'total_income' usando la mediana de 'total_in
total_income_median = df_cleaned['total_income'].median()
df_cleaned['total_income'] = df_cleaned['total_income'].fillna(total_income_median)

# Imputar los valores nulos en la columna 'days_employed' usando la mediana de 'days_em
days_employed_median = df_cleaned['days_employed'].median()
df_cleaned['days_employed'] = df_cleaned['days_employed'].fillna(days_employed_median)

# Comprobar valores nulos en todas las columnas
null_counts = df_cleaned.isnull().sum()

# Mostrar la cantidad de valores nulos por columna
print(null_counts)

# Verificar si hay algún valor nulo en la columna 'total_income'
if df_cleaned['total_income'].isnull().any():
    print("\nNo se pudieron corregir todos los valores nulos en las columnas.")
else:
    print("\nLos valores nulos en las columnas han sido corregidos.")
```

```
children            0
days_employed       0
dob_years           0
```

```
education           0
education_id        0
family_status       0
family_status_id    0
gender              0
income_type         0
debt                0
total_income        0
purpose             0
age_category        0
dtype: int64

Los valores nulos en las columnas han sido corregidos.
```

Respuesta del estudiante Se le hizo la correccion pertinente al codigo para que no haya datos nulos en la columna $\rightarrow tal_{\in} come$ y la columna $days_{e}mployed$ tambien fue corregida.

Clasificación de datos

In [63]:

```
# Muestra los valores de los datos seleccionados para la clasificación

# Mostrar los valores de la columna 'children'
print("Valores de la columna 'children':")
print(df_cleaned['children'].value_counts())

# Mostrar los valores de la columna 'days_employed'
print("\nValores de la columna 'days_employed':")
print(df_cleaned['days_employed'].value_counts())

# Mostrar los valores de la columna 'dob_years'
print("\nValores de la columna 'dob_years':")
print(df_cleaned['dob_years'].value_counts())

# Mostrar los valores de la columna 'education'
print("\nValores de la columna 'education':")
print(df_cleaned['education'].value_counts())

# Mostrar los valores de la columna 'education_id'
print("\nValores de la columna 'education_id':")
print(df_cleaned['education_id'].value_counts())

# Mostrar los valores de la columna 'family_status'
print("\nValores de la columna 'family_status':")
print(df_cleaned['family_status'].value_counts())

# Mostrar los valores de la columna 'family_status_id'
print("\nValores de la columna 'family_status_id':")
print(df_cleaned['family_status_id'].value_counts())

# Mostrar los valores de la columna 'gender'
print("\nValores de la columna 'gender':")
print(df_cleaned['gender'].value_counts())

# Mostrar los valores de la columna 'income_type'
print("\nValores de la columna 'income_type':")
print(df_cleaned['income_type'].value_counts())

# Mostrar los valores de la columna 'debt'
```

```python
print("\nValores de la columna 'debt':")
print(df_cleaned['debt'].value_counts())

# Mostrar los valores de la columna 'total_income'
print("\nValores de la columna 'total_income':")
print(df_cleaned['total_income'].value_counts())

# Mostrar los valores de la columna 'purpose'
print("\nValores de la columna 'purpose':")
df_cleaned['purpose'].value_counts()
```

```
Valores de la columna 'children':
0    14214
1     4808
2     2052
3      330
4       41
5        9
Name: children, dtype: int64

Valores de la columna 'days_employed':
1630.019381    5548
142.276217        1
144.185854        1
2569.204627       1
3545.955468       1
               ...
2152.475526       1
6219.157426       1
5873.586442       1
3355.260838       1
1636.419775       1
Name: days_employed, Length: 15907, dtype: int64

Valores de la columna 'dob_years':
35.0    616
43.0    613
40.0    607
41.0    605
34.0    601
38.0    597
42.0    596
33.0    581
39.0    572
31.0    559
36.0    554
44.0    545
29.0    544
30.0    537
48.0    536
37.0    536
50.0    513
32.0    509
49.0    508
28.0    503
45.0    496
27.0    493
52.0    484
56.0    483
47.0    477
54.0    476
46.0    472
53.0    459
57.0    456
```

```
58.0    454
51.0    446
55.0    443
59.0    443
26.0    408
60.0    374
25.0    357
61.0    354
62.0    348
63.0    269
24.0    264
64.0    260
23.0    252
65.0    193
22.0    183
66.0    182
67.0    167
21.0    111
68.0     99
69.0     85
70.0     65
71.0     56
20.0     51
72.0     33
19.0     14
73.0      8
74.0      6
75.0      1
Name: dob_years, dtype: int64

Valores de la columna 'education':
secondary education    15172
bachelor's degree       5250
some college             744
primary education        282
graduate degree            6
Name: education, dtype: int64

Valores de la columna 'education_id':
1    15172
0     5250
2      744
3      282
4        6
Name: education_id, dtype: int64

Valores de la columna 'family_status':
married              12339
civil partnership     4151
unmarried             2810
divorced              1195
widow / widower        959
Name: family_status, dtype: int64

Valores de la columna 'family_status_id':
0    12339
1     4151
4     2810
3     1195
2      959
Name: family_status_id, dtype: int64

Valores de la columna 'gender':
F    14175
M     7279
```

```
Name: gender, dtype: int64

Valores de la columna 'income_type':
employee         11084
business          5078
retiree           3829
civil servant     1457
other                6
Name: income_type, dtype: int64

Valores de la columna 'debt':
0    19713
1     1741
Name: debt, dtype: int64

Valores de la columna 'total_income':
23202.870    2104
42413.096       2
17312.717       2
31791.384       2
55362.332       1
             ...
27715.458       1
23834.534       1
26124.613       1
28692.182       1
41428.916       1
Name: total_income, Length: 19348, dtype: int64

Valores de la columna 'purpose':
```

Out[63]:

```
wedding ceremony                            791
having a wedding                            768
to have a wedding                           765
real estate transactions                    675
buy commercial real estate                  661
housing transactions                        652
buying property for renting out             651
transactions with commercial real estate    650
purchase of the house                       646
housing                                     646
purchase of the house for my family         638
construction of own property                635
property                                    633
transactions with my real estate            627
building a real estate                      624
buy real estate                             621
purchase of my own house                    620
building a property                         619
housing renovation                          607
buy residential real estate                 606
buying my own car                           505
going to university                         496
car                                         494
second-hand car purchase                    486
cars                                        478
to own a car                                478
buying a second-hand car                    478
to buy a car                                471
car purchase                                461
supplementary education                     460
purchase of a car                           455
university education                        452
education                                   447
to get a supplementary education            446
getting an education                        442
```

```
profile education                           436
getting higher education                    426
to become educated                          408
Name: purpose, dtype: int64
```

In [64]:

```python
# Comprobar los valores únicos

# Obtener una lista de las columnas de clasificación
classification_columns = ['children', 'days_employed', 'dob_years', 'education', 'educa
                          'family_status', 'family_status_id', 'gender', 'income_type',
                          'total_income', 'purpose']

# Mostrar los valores únicos en cada columna de clasificación
for column in classification_columns:
    print(f"Valores únicos en '{column}':")
    print(df_cleaned[column].unique())
    print("----------------------------")
```

```
Valores únicos en 'children':
[1 0 3 2 4 5]
----------------------------
Valores únicos en 'days_employed':
[8437.67302776 4024.80375385 5623.42261023 ... 2113.3468877  3112.4817052
 1984.50758853]
----------------------------
Valores únicos en 'dob_years':
[42. 36. 33. 32. 53. 27. 43. 50. 35. 41. 40. 65. 54. 56. 26. 48. 24. 21.
 57. 67. 28. 63. 62. 47. 34. 68. 25. 31. 30. 20. 49. 37. 45. 61. 64. 44.
 52. 46. 23. 38. 39. 51. 59. 29. 60. 55. 58. 71. 22. 73. 66. 69. 19. 72.
 70. 74. 75.]
----------------------------
Valores únicos en 'education':
["bachelor's degree" 'secondary education' 'some college'
 'primary education' 'graduate degree']
----------------------------
Valores únicos en 'education_id':
[0 1 2 3 4]
----------------------------
Valores únicos en 'family_status':
['married' 'civil partnership' 'widow / widower' 'divorced' 'unmarried']
----------------------------
Valores únicos en 'family_status_id':
[0 1 2 3 4]
----------------------------
Valores únicos en 'gender':
['F' 'M']
----------------------------
Valores únicos en 'income_type':
['employee' 'retiree' 'business' 'civil servant' 'other']
----------------------------
Valores únicos en 'debt':
[0 1]
----------------------------
Valores únicos en 'total_income':
[40620.102 17932.802 23341.752 ... 14347.61  39054.888 13127.587]
----------------------------
Valores únicos en 'purpose':
['purchase of the house' 'car purchase' 'supplementary education'
 'to have a wedding' 'housing transactions' 'education' 'having a wedding'
 'purchase of the house for my family' 'buy real estate'
 'buy commercial real estate' 'buy residential real estate'
 'construction of own property' 'property' 'building a property'
 'buying a second-hand car' 'buying my own car'
```

```
 'transactions with commercial real estate' 'building a real estate'
 'housing' 'transactions with my real estate' 'cars' 'to become educated'
 'second-hand car purchase' 'getting an education' 'car'
 'wedding ceremony' 'to get a supplementary education'
 'purchase of my own house' 'real estate transactions'
 'getting higher education' 'to own a car' 'purchase of a car'
 'profile education' 'university education'
 'buying property for renting out' 'to buy a car' 'housing renovation'
 'going to university']
----------------------------
```

Respuesta del estudiante Podemos observar que las columnas se pueden usar como grupos aparte, para luego correlacionarlos y poder trabajar en la data agrupada, esto es lo que se puede apreciar en el codigo debajo y el que le sigue.

In [65]:

```
# Escribamos una función para clasificar los datos en función de temas comunes

def classify_data(df, classification_columns):
    """
    Clasifica los datos en función de temas comunes.

    Parámetros:
        - df: DataFrame que contiene los datos a clasificar.
        - classification_columns: Lista de columnas de clasificación en el DataFrame.

    Retorna:
        Un nuevo DataFrame con una columna adicional 'classification' que indica la cla
    """
    # Creamos una nueva columna 'classification' en el DataFrame
    df['classification'] = ''

    # Clasificamos los datos en función de las columnas de clasificación
    for column in classification_columns:
        if column == 'children':
            # Clasificar los datos de 'children'
            df['classification'] += df['children'].apply(lambda x: 'No Children' if x =
        elif column == 'dob_years':
            # Clasificar los datos de 'dob_years'
            df['classification'] += df['dob_years'].apply(lambda x: 'Young' if x <= 30
        elif column == 'income_type':
            # Clasificar los datos de 'income_type'
            df['classification'] += df['income_type'].apply(lambda x: x.title())
        elif column == 'debt':
            # Clasificar los datos de 'debt'
            df['classification'] += df['debt'].apply(lambda x: 'Has Debt' if x == 1 els
        elif column == 'total_income':
            # Clasificar los datos de 'total_income'
            df['classification'] += df['total_income'].apply(lambda x: 'Low Income' if
        elif column == 'education':
            # Clasificar los datos de 'education'
            df['classification'] += df['education'].apply(lambda x: x.title())
        elif column == 'family_status':
            # Clasificar los datos de 'family_status'
            df['classification'] += df['family_status'].apply(lambda x: x.title())
        elif column == 'gender':
            # Clasificar los datos de 'gender'
            df['classification'] += df['gender'].apply(lambda x: 'Female' if x == 'F' e
        elif column == 'purpose':
```

```
            # Clasificar los datos de 'purpose'
            df['classification'] += df['purpose'].apply(lambda x: x.title())
        elif column == 'days_employed':
            # Clasificar los datos de 'days_employed'
            df['classification'] += 'Days Employed'

    return df

# Clasificar los datos en función de las columnas identificadas previamente
classification_columns = ['children', 'dob_years', 'income_type', 'debt', 'total_income
df_classified = classify_data(df_cleaned, classification_columns)
```

In [66]:

```
# Crea una columna con las categorías y cuenta los valores en ellas

# Clasificar los datos en función de las columnas identificadas previamente
classification_columns = ['children', 'dob_years', 'income_type', 'debt', 'total_income
df_classified = classify_data(df_cleaned, classification_columns)

# Mostrar el DataFrame resultante con la nueva columna 'classification'
df_classified
```

Out[66]:

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	ge
0	1	8437.673028	42.0	bachelor's degree	0	married	0	
1	1	4024.803754	36.0	secondary education	1	married	0	
2	0	5623.422610	33.0	secondary education	1	married	0	
3	3	4124.747207	32.0	secondary education	1	married	0	
4	0	1630.019381	53.0	secondary education	1	civil partnership	1	
...	...	...	...	...	...	...	...	
21449	1	4529.316663	43.0	secondary education	1	civil partnership	1	
21450	0	1630.019381	67.0	secondary education	1	married	0	
21451	1	2113.346888	38.0	secondary education	1	civil partnership	1	
21452	3	3112.481705	38.0	secondary education	1	married	0	

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	ge
21453	2	1984.507589	40.0	secondary education	1	married	0	

21454 rows × 14 columns

In [67]:

```
# Revisar todos los datos numéricos en la columna seleccionada para la clasificación
```

In [68]:

```
# Obtener estadísticas resumidas para la columna
```

Respuesta del estudiante Los rangos que utilizare seran los mas evidentes, en $\chi ldren$, dividire en 4 grupos dependiendo la cantidad de hijos, en $\rightarrow tal_{\in} come$ dividire en 4 grupos por la cantidad de dinero que gana el cliente, en la edad del cliente $dob_y ears$, dividire por cantidad de edad en 4 grupos tambien, y asi trabajare con estas que son las mas representativas y las cuales me podrian proveer mejor informacion.

In [69]:

```
# Crear una función para clasificar en diferentes grupos numéricos basándose en rangos

# Definir la función 'classify_by_ranges'
def classify_by_ranges(value, ranges):
    for category, (lower_bound, upper_bound) in ranges.items():
        if lower_bound <= value <= upper_bound:
            return category
    return None

# Si aún no has calculado los cuartiles, puedes hacerlo de la siguiente manera:
total_income_quartiles = df_cleaned['total_income'].describe().loc[['25%', '50%', '75%'

# Definir los rangos para 'children'
children_ranges = {
    '0': (0, 0),
    '1-2': (1, 2),
    '3-5': (3, 5),
    '6 o más': (6, float('inf'))  # 'float('inf')' representa infinito
}

# Definir los rangos para 'total_income' usando cuartiles
total_income_ranges = {
    'Bajo': (df_cleaned['total_income'].min(), total_income_quartiles['25%']),
    'Medio-bajo': (total_income_quartiles['25%'], total_income_quartiles['50%']),
    'Medio-alto': (total_income_quartiles['50%'], total_income_quartiles['75%']),
    'Alto': (total_income_quartiles['75%'], df_cleaned['total_income'].max())
}

# Definir los rangos para 'dob_years' basados en 'age_category'
dob_years_ranges = {
    'Joven': (0, 25),
    'Adulto joven': (26, 35),
    'Adulto': (36, 60),
    'Adulto mayor': (61, float('inf'))
```

```
}

# Clasificar un valor para 'children'
children_value = 3
children_category = classify_by_ranges(children_value, children_ranges)
print("Children Category:", children_category)

# Clasificar un valor para 'total_income'
total_income_value = 25000
total_income_category = classify_by_ranges(total_income_value, total_income_ranges)
print("Total Income Category:", total_income_category)

# Clasificar un valor para 'dob_years'
dob_years_value = 40
dob_years_category = classify_by_ranges(dob_years_value, dob_years_ranges)
print("DOB Years Category:", dob_years_category)
```

```
Children Category: 3-5
Total Income Category: Medio-alto
DOB Years Category: Adulto
```

In [70]:

```
# Crear una columna con categorías

# Función para clasificar valores basados en rangos
def classify_by_ranges(value, ranges):
    for category, (lower, upper) in ranges.items():
        if lower <= value <= upper:
            return category

# Crear la nueva columna 'children_category' con las categorías para 'children'
df_cleaned['children_category'] = df_cleaned['children'].apply(lambda x: classify_by_ra

# Crear la nueva columna 'total_income_category' con las categorías para 'total_income'
df_cleaned['total_income_category'] = df_cleaned['total_income'].apply(lambda x: classi

# Crear la nueva columna 'dob_years_category' con las categorías para 'dob_years'
df_cleaned['dob_years_category'] = df_cleaned['dob_years'].apply(lambda x: classify_by_

# Mostrar las primeras filas del DataFrame para verificar las nuevas columnas creadas
df_cleaned.head()
```

Out[70]:

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gender
0	1	8437.673028	42.0	bachelor's degree	0	married	0	F
1	1	4024.803754	36.0	secondary education	1	married	0	F
2	0	5623.422610	33.0	secondary education	1	married	0	M
3	3	4124.747207	32.0	secondary education	1	married	0	M
4	0	1630.019381	53.0	secondary education	1	civil partnership	1	F

children	days_employed	dob_years	education	education_id	family_status	family_status_id	gender

In [71]:

```
# Contar los valores de cada categoría para ver la distribución

# Contar los valores de cada categoría en la columna 'children_category'
children_counts = df_cleaned['children_category'].value_counts()

# Contar los valores de cada categoría en la columna 'total_income_category'
total_income_counts = df_cleaned['total_income_category'].value_counts()

# Contar los valores de cada categoría en la columna 'dob_years_category'
dob_years_counts = df_cleaned['dob_years_category'].value_counts()

# Mostrar la distribución de cada categoría
print("Distribución de 'children_category':")
print(children_counts)
print("---------------------------")

print("Distribución de 'total_income_category':")
print(total_income_counts)
print("---------------------------")

print("Distribución de 'dob_years_category':")
dob_years_counts
```

```
Distribución de 'children_category':
0      14214
1-2     6860
3-5      380
Name: children_category, dtype: int64
---------------------------
Distribución de 'total_income_category':
Medio-bajo    6415
Alto          5364
Bajo          5364
Medio-alto    4311
Name: total_income_category, dtype: int64
---------------------------
Distribución de 'dob_years_category':
```

Out[71]:

```
Adulto          12745
Adulto joven     5351
Adulto mayor     2126
Joven            1232
Name: dob_years_category, dtype: int64
```

Comprobación de las hipótesis

¿Existe una correlación entre tener hijos y pagar a tiempo?

In [72]:

```
# Comprueba los datos sobre los hijos y los pagos puntuales

# Contar los valores de cada categoría en 'children_category'
children_counts = df_cleaned['children_category'].value_counts()

# Calcular el porcentaje de personas que pagan puntualmente sus préstamos en la columna
debt_counts = df_cleaned['debt'].value_counts()
total_records = df_cleaned.shape[0]
```

```
percentage_punctual = (debt_counts[0] / total_records) * 100

# Calcular la tasa de incumplimiento en función del número de hijos
# Calcular la tasa de incumplimiento en función del número de hijos
debt_by_children = df_cleaned.groupby('children')['debt'].mean() * 100

# Imprimir los resultados
print("Tasa de incumplimiento en función del número de hijos:")
debt_by_children
```

```
Tasa de incumplimiento en función del número de hijos:
```

Out[72]:

```
children
0    7.541860
1    9.234609
2    9.454191
3    8.181818
4    9.756098
5    0.000000
Name: debt, dtype: float64
```

Conclusión

Respuesta del estudiante Segun se puede observar en los resultados, la correlacion entre la cantidad de hijos y pagar a tiempo, esta visible en el grupo de clientes que tiene 4 hijos, pero en los demas es algo borrosa, no parece tener una correlacion.

¿Existe una correlación entre la situación familiar y el pago a tiempo?

In [73]:

```
# Comprueba los datos del estado familiar y los pagos a tiempo

# Contar los valores de cada categoría en 'family_status'
family_status_counts = df_cleaned['family_status'].value_counts()

# Calcular el porcentaje de personas que pagan puntualmente sus préstamos en la columna
debt_counts = df_cleaned['debt'].value_counts()
total_records = df_cleaned.shape[0]
percentage_punctual = (debt_counts[0] / total_records) * 100

# Calcular la tasa de incumplimiento basada en el estado familiar
debt_by_family_status = df_cleaned.groupby('family_status')['debt'].mean() * 100

# Imprimir los resultados
print("Tasa de incumplimiento basada en el estado familiar:")
debt_by_family_status
```

```
Tasa de incumplimiento basada en el estado familiar:
```

Out[73]:

```
family_status
civil partnership    9.347145
divorced             7.112971
married              7.545182
unmarried            9.750890
widow / widower      6.569343
Name: debt, dtype: float64
```

Respuesta del estudiante Segun se puede observar en los resultados, los clientes con union libre y los no casados son los que tienen una tasa mas alta de incumplimiento en los pagos.

¿Existe una correlación entre el nivel de ingresos y el pago a tiempo?

In [74]:

```
# Comprueba los datos del nivel de ingresos y los pagos a tiempo

# Calcular los valores necesarios para los rangos de ingresos
min_income = df_cleaned['total_income'].min()
first_quartile = df_cleaned['total_income'].quantile(0.25)
second_quartile = df_cleaned['total_income'].quantile(0.50)
third_quartile = df_cleaned['total_income'].quantile(0.75)
max_income = df_cleaned['total_income'].max()

# Crear rangos para el nivel de ingresos
income_ranges = {
    'Bajo': (min_income, first_quartile),
    'Medio-bajo': (first_quartile, second_quartile),
    'Medio-alto': (second_quartile, third_quartile),
    'Alto': (third_quartile, max_income)
}

# Agregar una nueva columna al DataFrame con las categorías de ingresos
df_cleaned['income_category'] = pd.cut(df_cleaned['total_income'], bins=[min_income, fi

# Calcular la tasa de pagos a tiempo en función del nivel de ingresos
debt_by_income = df_cleaned.groupby('income_category')['debt'].mean() * 100

# Calcular la tasa de incumplimiento basada en el nivel de ingresos
# Imprimir los resultados
print("Tasa de pagos a tiempo en función del nivel de ingresos:")
debt_by_income
```

```
Tasa de pagos a tiempo en función del nivel de ingresos:
```

Out[74]:

```
income_category
Bajo          7.943315
Medio-bajo    8.526890
Medio-alto    8.907446
Alto          7.140194
Name: debt, dtype: float64
```

Conclusión

Respuesta del estudiante En este caso la correlacion no es muy visible, se puede observar que los clientes con una entrada de dinero media baja tienden mas a incumplir sus deudas, pero los que reciben menos dinero, cumplen mas, podria deberse a que a estos no les ofrecen los prestamos porque ya viene sobrentendido que tendran dificultades para realizar sus pagos a diferencia los que ganan mas dinero probablemente simplemente no solicitan tan a menudo un prestamo.

¿Cómo afecta el propósito del crédito a la tasa de incumplimiento?

In [75]:

```
# Consulta los porcentajes de tasa de incumplimiento para cada propósito del crédito y

# Calcular la tasa de incumplimiento para cada propósito del crédito
debt_by_purpose = df_cleaned.groupby('purpose')['debt'].mean() * 100

# Crear función para asignar nombres a los grupos
def categorize_purpose(purpose):
```

```
    if 'car' in purpose.lower():
        return 'purchase_a_car'
    elif any(keyword in purpose.lower() for keyword in ["education", "educated", "unive
        return 'better_education'
    if 'wedding' in purpose.lower():
        return 'get_marry'
    elif any(keyword in purpose.lower() for keyword in ["house", "estate", "property",
        return 'house_investment'
    else:
        return purpose

# Asignar nombres a los grupos
debt_by_purpose_grouped = debt_by_purpose.reset_index()
debt_by_purpose_grouped['purpose'] = debt_by_purpose_grouped['purpose'].apply(categoriz
debt_by_purpose_grouped = debt_by_purpose_grouped.groupby('purpose')['debt'].mean()

# Ordenar los resultados de manera descendente
debt_by_purpose_grouped = debt_by_purpose_grouped.sort_values(ascending=False)

# Imprimir los resultados
print("Tasa de incumplimiento para cada propósito del crédito:")
print(debt_by_purpose_grouped)
```

```
Tasa de incumplimiento para cada propósito del crédito:
purpose
purchase_a_car      9.369386
better_education    9.243703
get_marry           8.002019
house_investment    7.223079
Name: debt, dtype: float64
```

Respuesta del estudiante Aca he agrupado los resultados como sugeriste, para ser mostrados de una manera mas entendible y precisa.

Conclusión

Respuesta del estudiante Como podemos observar en el resultado de arriba, la mayor incidencia de incumplimiento se da en 2 tipos de propositos, en los propositos estudiantiles, y cuando el proposito es para comprar un vehiculo, estos 2 propositos tienen mayor riesgo de incumplimiento ya que la data es contundente al respecto.

Conclusión general

Respuesta del estudiante 1) Pudimos observar que segun la data no hay una correlacion tan fuerte en el incumplimiento de los pagos y la cantidad de hijos que tienen los clientes. 2)Tambien pudimos observar que no hay una correlacion fuerte entre la cantidad de dinero que gana el cliente y los incumplimientos 3) Tambien pudimos observar que el status familiar si tenia un poco mas de correlacion, pero no era lo suficiente como para ofrecer informacion concluyente. 4) Pudimos ver que la verdadera correlacion entre la data y el incumplimiento en los pagos se daba en clientes que tomaban prestamos para adquirir un vehiculo o para educacion. 5)Para llegar a estas conclusiones despues de trabajar la data, analizarla y desglosarla pudimos ver que para el analisis era mejor utilizar la mediana ya que como teniamos valores

atipicos era el metodo que menos afectaba los resultados finales de la investigacion, tambien, fue bueno tener en cuenta los graficos que usamos para poder darnos cuenta de los problemas que habian en las columnas $days_employed$ y $\rightarrow tal_{\in} come$, fue evidente que habia que trabajarlas para poder tener una investigacion de calidad, los valores ausentes probablemente estuvieron presentes debido a un problema tecnico, ya que no habia evidencia de que hubiera sido porque los clientes no proveyeran la data correspondiente, al igual que tambien los duplicados parecian por ello, en una proxima ocasion seria bueno tener en cuenta las conversiones de datos que se hacen antes de entregar el CSV con el cual se hara la investigacion, asi la data estara en mejores condiciones para ser trabajada.

Comentarios generales **Comentario del revisor** Hola, Carlos. Debemos trabajar en algunos puntos pendientes tanto de forma como de fondo para poder aprobar el proyecto. He dejado comentarios a lo largo del documento para ello.

Comentarios generales **Comentario del revisor** ¡Excelente trabajo, Carlos! Has corregido todas y cada una de las sugerencias y has aprobado un nuevo proyecto. ¡Felicitaciones!